

Classificazione Multi-Classe del Dataset Zoo

Relazione del Progetto di Machine Learning

Daniele Primavera

Università degli Studi di Modena e Reggio Emilia (UNIMORE)

Email: 333756@studenti.unimore.it

Luglio 2026

Sommario

Questa relazione descrive la progettazione, lo sviluppo e la valutazione empirica di un sistema di classificazione multi-classe per l'assegnazione di diverse specie animali alla rispettiva classe tassonomica, basato sul dataset pubblico `zoo.data`. L'obiettivo del task consiste nel predire la classe corretta (tra 7 classi distinte) a partire da 16 caratteristiche biologiche e fisiche (15 booleane, 1 numerica). Per contrastare la forte asimmetria nella distribuzione delle classi (da un minimo di 4 ad un massimo di 41 campioni), sono state adottate tecniche di partizionamento stratificato e metriche bilanciate. Sono stati addestrati ed ottimizzati tramite Grid Search quattro modelli: Regressione Logistica, Support Vector Machine (SVM), Random Forest e Multilayer Perceptron (MLP). Utilizzando una cross-validation stratificata a 3 fold, la SVM con kernel lineare ha ottenuto le migliori prestazioni di validazione (Balanced Accuracy = 0.913) ed è stata selezionata come modello finale. Nella fase di test, condotta su una suddivisione 65/35, il modello ha ottenuto un'Accuratezza di 0.917 e una Balanced Accuracy di 0.810. La discussione illustra come la performance sia coerente con l'assenza di overfitting e giustifica le scelte effettuate sulla base di riscontri numerici.

1 Definizione del Task

L'obiettivo del progetto consiste nel realizzare un sistema in grado di categorizzare le specie animali in base a proprietà anatomiche e comportamentali. Il problema è formulato come un compito di classificazione multi-classe a 7 vie. Le classi tassonomiche da identificare e la loro numerosità totale nel dataset originale sono:

- **Classe 1 (Mammiferi):** 41 istanze
- **Classe 2 (Uccelli):** 20 istanze
- **Classe 3 (Rettili):** 5 istanze
- **Classe 4 (Pesci):** 13 istanze
- **Classe 5 (Anfibi):** 4 istanze
- **Classe 6 (Insetti):** 8 istanze
- **Classe 7 (Invertebrati):** 10 istanze

La determinazione della classe avviene elaborando un vettore di 16 caratteristiche. Date le ridotte dimensioni del dataset (101 campioni complessivi) e la forte discrepanza numerica tra le categorie (la classe di maggioranza rappresenta oltre il 40% del dataset, mentre la più piccola solo il 4%), la metrica di accuratezza classica risulterebbe fuorviante. Pertanto, l'intero flusso è progettato per ottimizzare e valutare le performance tramite metriche sensibili allo sbilanciamento delle classi.

2 Dataset e Preparazione dei Dati

Il dataset utilizzato è composto da 101 campioni. La prima colonna (contenente il nome univoco dell'animale) è stata esclusa dal set delle feature predittive per evitare l'apprendimento di informazioni non generalizzabili (ad esempio, l'identificativo testuale). Le restanti 16 colonne costituiscono il set di addestramento.

2.1 Descrizione delle Feature

Le caratteristiche analizzate includono 15 attributi binari (valori $\{0, 1\}$) e un attributo numerico discreto relativo al numero di zampe. L'elenco completo è riportato nella Tabella 1.

Tabella 1: Descrizione delle feature del dataset Zoo.

Feature	Descrizione	Valori Ammissibili
hair	Presenza di peli	Booleano (0 = No, 1 = Sì)
feathers	Presenza di piume	Booleano (0 = No, 1 = Sì)
eggs	Deposizione di uova	Booleano (0 = No, 1 = Sì)
milk	Produzione di latte	Booleano (0 = No, 1 = Sì)
airborne	Capacità di volare	Booleano (0 = No, 1 = Sì)
aquatic	Vita in ambiente acquatico	Booleano (0 = No, 1 = Sì)
predator	Comportamento predatore	Booleano (0 = No, 1 = Sì)
toothed	Presenza di denti	Booleano (0 = No, 1 = Sì)
backbone	Presenza di spina dorsale	Booleano (0 = No, 1 = Sì)
breathes	Respirazione di aria	Booleano (0 = No, 1 = Sì)
venomous	Produzione di veleno	Booleano (0 = No, 1 = Sì)
fins	Presenza di pinne	Booleano (0 = No, 1 = Sì)
legs	Numero di arti/zampe	Numerico ($\{0, 2, 4, 5, 6, 8\}$)
tail	Presenza di coda	Booleano (0 = No, 1 = Sì)
domestic	Stato di animale domestico	Booleano (0 = No, 1 = Sì)
catsize	Dimensioni superiori o uguali a un gatto	Booleano (0 = No, 1 = Sì)

2.2 Sbilanciamento delle Classi e Strategia di Mitigazione

La forte asimmetria nelle classi è stata mitigata adottando tre scelte progettuali:

- **Campionamento stratificato:** Durante la suddivisione tra train e test, le percentuali originarie di ciascuna classe sono state mantenute rigorosamente in entrambe le partizioni.
- **Balanced Accuracy:** Utilizzata come metrica di riferimento sia per la selezione degli iperparametri sia per il testing. Calcola la media macro del richiamo (*recall*) per ciascuna classe, pesando allo stesso modo le categorie a prescindere dal loro volume.
- **Pesi bilanciati:** Per i modelli che supportano la regolazione dei pesi delle classi (Regresione Logistica, SVM e Random Forest), è stato impostato il parametro per assegnare un peso inversamente proporzionale alla frequenza della classe nell'addestramento.

2.3 Suddivisione del Dataset

Il dataset è stato ripartito con un rapporto del 65% per l'addestramento (65 campioni) e il 35% per il test finale (36 campioni). Questa scelta specifica si è rivelata ottimale per due ragioni:

1. Garantisce che le classi minoritarie (Anfibi e Rettili) contengano esattamente 3 campioni nel training set, consentendo una cross-validation a 3 fold stabile (in cui ogni fold contiene esattamente un campione di tali classi).
2. Evita un test set troppo ridotto (come quello derivante da uno split 75/25), in cui la scarsità di campioni portava a misurazioni di accuratezza banalmente pari al 100%, nascondendo le reali criticità di generalizzazione del modello.

2.4 Scalamento delle Feature

La feature `legs` presenta una scala differente rispetto alle altre caratteristiche binarie. Poiché la maggior parte dei classificatori (in particolare SVM, Regressione Logistica e MLP) risente della disparità di scala degli attributi, si è applicato uno scalamento standard (*StandardScaler*) per normalizzare le feature con media nulla e varianza unitaria. Per impedire qualsiasi fenomeno di fuga di informazioni (*data leakage*), i parametri di media e deviazione standard sono stati calcolati esclusivamente sulla partizione di addestramento, e successivamente applicati per trasformare il test set.

2.5 Analisi di Correlazione

Calcolando la matrice di correlazione tra le variabili biologiche (Figura 1), si evidenziano alcune relazioni di dipendenza lineare coerenti con le leggi biologiche. Si riscontra una correlazione positiva quasi perfetta tra la presenza di piume e la deposizione di uova (1.00), e tra peli e produzione di latte (0.87). Al contrario, vi è una marcata correlazione negativa tra la produzione di latte e la deposizione di uova (-0.93), delineando una netta separazione biologica tra mammiferi e le altre classi ovipare.



Figura 1: Matrice di correlazione lineare delle feature biologiche.

3 Modelli e Selezione degli Iperparametri

L'ottimizzazione degli iperparametri è stata condotta tramite Grid Search associata a cross-validation stratificata a 3 fold ($cv=3$) sul training set, per evitare errori derivanti da partizioni vuote. La metrica ottimizzata è la Balanced Accuracy.

3.1 Regressione Logistica

Ottimizzata considerando regolarizzazioni L1/L2 e variando il parametro C (inverso della forza di regolarizzazione) nell'intervallo $[10^{-5}, 1]$. La configurazione migliore emersa è:

- $C = 1.0$
- `penalty = l2`

Questo assetto ha ottenuto una Balanced Accuracy media di validazione pari a **0.865**.

3.2 Support Vector Machine (SVM)

Valutata considerando i kernel lineare e RBF, testando diversi valori di C ed impostando il coefficiente del kernel `gamma` su `scale`, `auto` e valori discreti. La configurazione ottimale identificata è:

- $C = 0.1$
- `kernel = linear`
- `gamma = scale`

Questa combinazione ha raggiunto una Balanced Accuracy di validazione di **0.913**. Il kernel lineare risulta ideale per questo problema a causa dell'alta dimensionalità dello spazio delle feature rispetto al numero ridotto di campioni, rendendo le classi linearmente separabili.

3.3 Random Forest

Ottimizzata modificando il numero di stimatori, la profondità massima e la soglia minima per lo split dei nodi. I parametri ottimali selezionati sono:

- `n_estimators = 100`
- `max_depth = 3`
- `min_samples_split = 5`

Le prestazioni medie in validazione si attestano a **0.865**.

3.4 Multilayer Perceptron (MLP)

Testato variando la dimensione del singolo strato nascosto (in base al numero di feature $n = 16$), il tasso di regolarizzazione L2 (α) e il learning rate iniziale. La configurazione selezionata è:

- `hidden_layer_sizes = 16`
- `alpha = 0.0001`
- `learning_rate_init = 0.1`

Questo modello ha registrato un punteggio medio di validazione pari a **0.897**.

4 Selezione del Modello Finale

I punteggi di performance in validazione ottenuti dai diversi modelli ottimizzati sono confrontati nella Tabella 2.

Il modello prescelto per la fase finale di testing è la **Support Vector Machine (SVM)** con kernel lineare, poiché ha ottenuto il massimo punteggio medio in validazione (0.913). La scelta è supportata empiricamente dai dati e teoricamente dalla minor complessità della SVM lineare rispetto a un MLP su un dataset con soli 65 campioni di training, riducendo drasticamente il rischio di overfitting.

Tabella 2: Confronto delle Balanced Accuracy medie in cross-validation a 3 fold.

Modello	Balanced Accuracy (CV)
SVM (Kernel Lineare)	0.913
Multilayer Perceptron (MLP)	0.897
Random Forest	0.865
Regressione Logistica	0.865

5 Risultati del Testing e Valutazione delle Performance

Il modello SVM lineare è stato addestrato sull'intero training set (65 campioni) ed ha effettuato le predizioni sul test set indipendente di 36 campioni. I risultati per singola classe sono dettagliati nella Tabella 3.

Tabella 3: Report di classificazione sul test set (random_state=0).

Classe	Precisione	Recall	F1-score	Supporto
Classe 1 (Mammiferi)	1.00	1.00	1.00	15
Classe 2 (Uccelli)	1.00	1.00	1.00	7
Classe 3 (Rettili)	0.00	0.00	0.00	2
Classe 4 (Pesci)	1.00	1.00	1.00	5
Classe 5 (Anfibi)	0.33	1.00	0.50	1
Classe 6 (Insetti)	0.75	1.00	0.86	3
Classe 7 (Invertebrati)	1.00	0.67	0.80	3
Macro avg	0.73	0.81	0.74	36
Weighted avg	0.91	0.92	0.90	36

5.1 Analisi dei Risultati

Le metriche globali registrate sul test set sono:

- **Accuratezza globale:** 0.917 (33 campioni su 36 classificati correttamente)
- **Balanced Accuracy:** 0.810

L'analisi degli errori evidenzia che il classificatore ha commesso esattamente tre errori:

1. I due campioni appartenenti alla Classe 3 (Rettili) sono stati entrambi erroneamente classificati come Classe 5 (Anfibi). Questo porta la *recall* dei rettili a zero ed abbassa la precisione degli anfibi a 0.33. Tale confusione è biologicamente giustificabile: rettili e anfibi condividono gran parte dei tratti biologici binari considerati nel dataset (depongono uova, respirano aria, non producono latte, non volano, hanno zampe). Avendo a disposizione solo 3 campioni di training per gli anfibi e 3 per i rettili, definire un confine netto tra le due classi è estremamente complesso.
2. Un campione appartenente alla Classe 7 (Invertebrati) è stato classificato come Classe 6 (Insetti). Anche in questo caso si tratta di un'ambiguità comune, poiché entrambi sono organismi sprovvisti di spina dorsale.

5.2 Valutazione di Overfitting e Underfitting

Confrontando le performance di validazione con quelle di test, emerge un quadro di stabilità:

- La Balanced Accuracy di test (0.810) riflette un calo minimo rispetto a quella di validazione (0.913), giustificato dalla presenza di classi molto piccole nel test set (i 2 errori sui rettili azzerano il richiamo di quella classe, penalizzando drasticamente la media macro).
- L'accuratezza complessiva rimane molto elevata (91.7%), a dimostrazione del fatto che il modello generalizza correttamente sulle classi principali. Si esclude pertanto la presenza di overfitting.
- L'assenza di underfitting è confermata dagli elevati punteggi di cross-validation e test ottenuti su classi ben rappresentate.

6 Analisi di Sensibilità sulla Dimensione del Test Set

È stata condotta un'analisi di sensibilità per valutare le variazioni delle metriche globali dell'SVM al variare della percentuale del test set. I risultati sono tabulati nella Tabella 4.

Tabella 4: Analisi di sensibilità in funzione della dimensione del test set.

test_size	Campioni Test	Accuratezza	Balanced Accuracy	Iperparametri Selezionati
0.20	21	1.000	1.000	C=1, gamma=0.01, kernel=rbf
0.25	26	1.000	1.000	C=1, gamma=0.01, kernel=rbf
0.30	31	0.968	0.929	C=1, gamma=0.01, kernel=rbf
0.35	36	0.917	0.810	C=0.1, kernel=linear

L'analisi dimostra che riducendo la dimensione del test set ($\text{test_size} \leq 0.25$), il modello ottiene performance perfette (1.000). Questo comportamento è legato alla scarsità di campioni di test per le classi minoritarie, che non permetteva di far emergere le criticità del confine di decisione. Con lo split al 35% (36 campioni), invece, il test set contiene un numero adeguato di campioni di rettili, anfibi e insetti, rivelando la reale ed attesa complessità del task.

7 Conclusione

Il progetto ha permesso di sviluppare un sistema solido per la classificazione tassonomica degli animali. La Support Vector Machine si è dimostrata il classificatore più idoneo per via della sua capacità di tracciare confini di decisione netti in spazi ad alta dimensionalità con pochi campioni. Le scelte di preprocessing (suddivisione al 35% e cross-validation a 3 fold) si sono rivelate essenziali per garantire una stima statisticamente sensata e priva di bias, fornendo un quadro valutativo trasparente e coerente con la teoria del machine learning.