

Classificazione Multi-Classe del Dataset Zoo

Relazione del Progetto di Machine Learning

Daniele Primavera

Università degli Studi di Modena e Reggio Emilia (UNIMORE)

Email: 333756@studenti.unimore.it

Luglio 2026

Sommario

Questa relazione descrive la progettazione, lo sviluppo e la valutazione empirica di un sistema di classificazione multi-classe per l'assegnazione di diverse specie animali alla rispettiva classe tassonomica, basato sul dataset pubblico `zoo.data`. L'obiettivo del task consiste nel predire la classe corretta (tra 7 classi distinte) a partire da 16 caratteristiche biologiche e fisiche (15 booleane, 1 numerica). Il dataset originale (101 campioni) è stato ripulito rimuovendo l'istanza fuori dominio "`girl`" e normalizzando le due istanze di "`frog`" (rana comune e velenosa) per evitare la perdita di campioni in classi fortemente minoritarie. Per contrastare la forte asimmetria nella distribuzione delle classi (da un minimo di 4 a un massimo di 40 campioni), sono state adottate tecniche di partizionamento stratificato e metriche bilanciate. Sono stati addestrati ed ottimizzati tramite Grid Search quattro modelli: Regressione Logistica, Support Vector Machine (SVM), Random Forest e Multilayer Perceptron (MLP). Utilizzando una cross-validation stratificata a 3 fold, la SVM con kernel RBF ha ottenuto le migliori prestazioni di validazione (Balanced Accuracy = 0.913) ed è stata selezionata come modello finale. Nella fase di test, condotta su una suddivisione 65/35, il modello ha ottenuto un'Accuratezza di 0.943 e una Balanced Accuracy di 0.786. La discussione illustra come la performance sia coerente con l'assenza di overfitting e giustifica le scelte effettuate sulla base di riscontri numerici.

1 Definizione del Task

L'obiettivo del progetto consiste nel realizzare un sistema in grado di categorizzare le specie animali in base a proprietà anatomiche e comportamentali. Il problema è formulato come un compito di classificazione multi-classe a 7 vie. A seguito della rimozione dell'istanza anomala "`girl`", le classi tassonomiche da identificare e la loro numerosità totale nel dataset modificato sono:

- **Classe 1 (Mammiferi):** 40 istanze (ridotte da 41 dopo l'eliminazione di "`girl`")
- **Classe 2 (Uccelli):** 20 istanze
- **Classe 3 (Rettili):** 5 istanze
- **Classe 4 (Pesci):** 13 istanze
- **Classe 5 (Anfibi):** 4 istanze
- **Classe 6 (Insetti):** 8 istanze
- **Classe 7 (Invertebrati):** 10 istanze

La determinazione della classe avviene elaborando un vettore di 16 caratteristiche. Date le ridotte dimensioni del dataset (100 campioni complessivi) e la forte discrepanza numerica tra le categorie (la classe di maggioranza rappresenta il 40% del dataset, mentre la più piccola solo il 4%), la metrica di accuratezza classica risulterebbe fuorviante. Pertanto, l'intero flusso è progettato per ottimizzare e valutare le performance tramite metriche sensibili allo sbilanciamento delle classi.

2 Dataset e Preparazione dei Dati

Il dataset originale conteneva 101 campioni. La prima colonna (contenente il nome univoco dell'animale) è stata esclusa dal set delle feature predittive per evitare l'apprendimento di informazioni non generalizzabili. Le restanti 16 colonne costituiscono il set di addestramento.

2.1 Descrizione delle Feature

Le caratteristiche analizzate includono 15 attributi binari (valori $\{0, 1\}$) e un attributo numerico discreto relativo al numero di zampe. L'elenco completo è riportato nella Tabella 1.

Tabella 1: Descrizione delle feature del dataset Zoo.

Feature	Descrizione	Valori Ammissibili
hair	Presenza di peli	Booleano (0 = No, 1 = Sì)
feathers	Presenza di piume	Booleano (0 = No, 1 = Sì)
eggs	Deposizione di uova	Booleano (0 = No, 1 = Sì)
milk	Produzione di latte	Booleano (0 = No, 1 = Sì)
airborne	Capacità di volare	Booleano (0 = No, 1 = Sì)
aquatic	Vita in ambiente acquatico	Booleano (0 = No, 1 = Sì)
predator	Comportamento predatore	Booleano (0 = No, 1 = Sì)
toothed	Presenza di denti	Booleano (0 = No, 1 = Sì)
backbone	Presenza di spina dorsale	Booleano (0 = No, 1 = Sì)
breathes	Respirazione di aria	Booleano (0 = No, 1 = Sì)
venomous	Produzione di veleno	Booleano (0 = No, 1 = Sì)
fins	Presenza di pinne	Booleano (0 = No, 1 = Sì)
legs	Numero di arti/zampe	Numerico ($\{0, 2, 4, 5, 6, 8\}$)
tail	Presenza di coda	Booleano (0 = No, 1 = Sì)
domestic	Stato di animale domestico	Booleano (0 = No, 1 = Sì)
catsize	Dimensioni superiori o uguali a un gatto	Booleano (0 = No, 1 = Sì)

2.2 Pulizia dei Dati e Gestione delle Anomalie

Durante la fase preliminare del progetto, sono state riscontrate e risolte due anomalie significative presenti nei dati originali:

- **Istanza "girl"**: Faceva riferimento a un essere umano. Pur possedendo i tratti biologici della classe dei Mammiferi, rappresenta un outlier semantico e fuori dominio (*out-of-distribution*) per un classificatore orientato alla zoologia. Questa riga è stata fisicamente eliminata, riducendo la numerosità totale da 101 a 100.
- **Istanze "frog"**: Il dataset originale conteneva due righe con lo stesso nome identificativo. Un'analisi delle feature ha rivelato che non si trattava di un duplicato: la prima istanza presentava la proprietà **venomous** = 0 (rana comune), mentre la seconda presentava **venomous** = 1 (riferibile a specie di anfibii velenosi). Data la scarsità della classe degli Anfibi (4 istanze originarie), l'eliminazione di un campione avrebbe causato una perdita di diversità

biologica e una forte instabilità nei fold di validazione. Le due righe sono state pertanto mantenute ma rinominate in `frog_common` e `frog_venomous` per chiarezza formale.

2.3 Sbilanciamento delle Classi e Strategia di Mitigazione

La forte asimmetria nelle classi è stata mitigata adottando tre scelte progettuali:

- **Campionamento stratificato:** Durante la suddivisione tra train e test, le percentuali originarie di ciascuna classe sono state mantenute in entrambe le partizioni.
- **Balanced Accuracy:** Utilizzata come metrica di riferimento sia per la selezione degli iperparametri sia per il testing, calcolando la media macro del richiamo (*recall*) per ciascuna classe.
- **Pesi bilanciati:** Per i modelli che lo consentono, è stato configurato l'adeguamento automatico dei pesi in modo inversamente proporzionale alla frequenza delle classi nell'addestramento.

2.4 Suddivisione del Dataset

Il dataset ripulito (100 campioni) è stato ripartito con un rapporto del 65% per l'addestramento (65 campioni) e il 35% per il test finale (35 campioni). Questa scelta si è rivelata ottimale in quanto:

1. Garantisce che le classi minoritarie (Anfibi e Rettili) contengano esattamente 3 campioni nel training set, consentendo una cross-validation a 3 fold stabile (in cui ogni fold contiene esattamente un campione di tali classi).
2. Evita un test set troppo ridotto (come quello derivante da uno split 75/25 o 80/20), in cui la scarsità di campioni porta a misurazioni di accuratezza banalmente pari al 100%, nascondendo le reali criticità di generalizzazione del modello (come confermato dall'analisi di sensibilità della Sezione 6).

2.5 Scalamento delle Feature

La feature `legs` presenta una scala differente rispetto alle altre caratteristiche binarie. Si è applicato uno scalamento standard (*StandardScaler*) per normalizzare le feature con media nulla e varianza unitaria. Per impedire fenomeni di fuga di informazioni (*data leakage*), i parametri di standardizzazione sono stati calcolati esclusivamente sulla partizione di addestramento e successivamente applicati per trasformare il test set.

2.6 Analisi di Correlazione

La matrice di correlazione tra le variabili biologiche (Figura 1) evidenzia alcune importanti relazioni coerenti con le leggi biologiche, come la forte correlazione positiva tra piume e uova (1.00) e tra peli e produzione di latte (0.87), e una marcata correlazione negativa tra latte e deposizione di uova (-0.93), delineando una netta separazione tra mammiferi e specie ovipare.

3 Modelli e Selezione degli Iperparametri

L'ottimizzazione degli iperparametri è stata condotta tramite Grid Search associata a cross-validation stratificata a 3 fold (`cv=3`) sul training set. La metrica ottimizzata è la Balanced Accuracy.




Figura 1: Matrice di correlazione lineare delle feature biologiche.

3.1 Regressione Logistica (Softmax Regression)

La Regressione Logistica per classificazione multi-classe a 7 vie viene eseguita come una **Softmax Regression**. Il modello calcola un punteggio lineare per ciascuna classe e applica la funzione Softmax per ottenere una distribuzione di probabilità normalizzata sulle 7 categorie tassonomiche. Migliore configurazione trovata: $C = 5 \times 10^{-5}$, $\text{penalty} = 12$. Questo assetto ha ottenuto una Balanced Accuracy media di validazione pari a **0.902**.

3.2 Support Vector Machine (SVM)

La configurazione ottimale identificata è: $C = 1$, $\text{kernel} = \text{rbf}$, $\text{gamma} = \text{scale}$. Questa combinazione ha raggiunto una Balanced Accuracy di validazione di **0.913**. Il kernel a base radiale (RBF) consente di tracciare confini decisionali non lineari robusti, ideali per separare le classi minoritarie che presentano sovrapposizioni nelle feature biologiche binarie.

3.3 Random Forest

I parametri ottimali selezionati sono: $n_estimators = 150$, $\text{max_depth} = 3$, $\text{min_samples_split} = 5$. Le prestazioni medie in validazione si attestano a **0.860**.

3.4 Multilayer Perceptron (MLP)

La configurazione selezionata è: $\text{hidden_layer_sizes} = 32$, $\alpha = 0.0001$, $\text{learning_rate_init} = 0.01$. Questo modello ha registrato un punteggio medio di validazione pari a **0.902**.

4 Selezione del Modello Finale

I punteggi di performance in validazione ottenuti dai diversi modelli ottimizzati sono confrontati nella Tabella 2.

Il modello prescelto per la fase finale di testing è la **Support Vector Machine (SVM)** con kernel RBF, poiché ha ottenuto il massimo punteggio medio in validazione (0.913). La scelta è supportata empiricamente dai dati e teoricamente dalla capacità dell'SVM di mappare le feature in uno spazio non lineare per tracciare confini decisionali più fluidi e resistenti al rumore derivante da classi contigue.

Tabella 2: Confronto delle Balanced Accuracy medie in cross-validation a 3 fold.

Modello	Balanced Accuracy (CV)
SVM (Kernel RBF)	0.913
Regressione Logistica (Softmax Regression)	0.902
Multilayer Perceptron (MLP)	0.902
Random Forest	0.860

5 Risultati del Testing e Valutazione delle Performance

Il modello SVM con kernel RBF è stato addestrato sull'intero training set (65 campioni) ed ha effettuato le predizioni sul test set indipendente di 35 campioni. I risultati per singola classe sono dettagliati nella Tabella 3.

Tabella 3: Report di classificazione sul test set (random_state=0).

Classe	Precisione	Recall	F1-score	Supporto
Classe 1 (Mammiferi)	1.00	1.00	1.00	14
Classe 2 (Uccelli)	1.00	1.00	1.00	7
Classe 3 (Rettili)	0.50	0.50	0.50	2
Classe 4 (Pesci)	1.00	1.00	1.00	5
Classe 5 (Anfibi)	0.00	0.00	0.00	1
Classe 6 (Insetti)	1.00	1.00	1.00	3
Classe 7 (Invertebrati)	1.00	1.00	1.00	3
Macro avg	0.79	0.79	0.79	35
Weighted avg	0.94	0.94	0.94	35

5.1 Analisi dei Risultati

Le metriche globali registrate sul test set di 35 campioni sono:

- **Accuratezza globale:** 0.943 (33 campioni su 35 classificati correttamente)
- **Balanced Accuracy:** 0.786

L'analisi degli errori evidenzia che il classificatore ha commesso esattamente due errori:

1. Un campione appartenente alla Classe 3 (Rettili) è stato erroneamente classificato come Classe 5 (Anfibi).
2. L'unico campione della Classe 5 (Anfibi) è stato erroneamente classificato come Classe 3 (Rettili).

Questa mutua confusione tra rettili ed anfibi è biologicamente coerente: entrambe le classi condividono molti attributi anatomici (come la deposizione di uova, l'assenza di peli/piume e lo stato di sangue freddo). Con soli 3 esempi di training per classe, definire un iperpiano separatore perfetto in questa zona dello spazio delle feature risulta ostico, portando a questa limitata e reciproca ambiguità. Rispetto al dataset originale (non ripulito), l'errore che confondeva invertebrati e insetti è stato invece completamente risolto, registrando il 100% di metriche per entrambe le categorie.

5.2 Valutazione di Overfitting e Underfitting

Confrontando le performance di validazione con quelle di test, emerge un quadro di stabilità:

- La Balanced Accuracy di test (0.786) è allineata con le aspettative. Il calo rispetto al punteggio di validazione (0.913) è puramente matematico, dovuto al fatto che l'unico campione della classe Anfibi è stato errato, azzerandone il richiamo e pesando per 1/7 sulla media macro.
- L'accuratezza complessiva di test (94.3%) è persino superiore a quella del modello pre-pulizia (91.7%), evidenziando la bontà della rimozione dell'outlier "girl". Si esclude la presenza di overfitting.
- L'assenza di underfitting è confermata dagli ottimi punteggi sia in validazione che sulle classi principali nel test set.

6 Analisi di Sensibilità sulla Dimensione del Test Set

È stata condotta un'analisi di sensibilità per valutare le variazioni delle metriche globali dell'SVM al variare della percentuale del test set sul dataset modificato. I risultati sono tabulati nella Tabella 4.

Tabella 4: Analisi di sensibilità in funzione della dimensione del test set.

test_size	Campioni Test	Accuratezza	Balanced Accuracy	Iperparametri Selezionati
0.20	20	1.000	1.000	C=0.1, gamma=scale, kernel=linear
0.25	25	1.000	1.000	C=1, gamma=0.01, kernel=rbf
0.30	30	0.967	0.929	C=1, gamma=0.01, kernel=rbf
0.35	35	0.943	0.786	C=1, gamma=scale, kernel=rbf

L'analisi conferma che riducendo la dimensione del test set ($\text{test_size} \leq 0.25$, corrispondente a split 80/20 e 75/25), il modello ottiene performance perfette (1.000) poiché il test set ridotto non cattura la reale complessità delle classi minoritarie. Con lo split al 30% (30 campioni), si registra un'accuratezza di 0.967 e una balanced accuracy di 0.929. Infine, con lo split al 35% (35 campioni), si evidenzia la reale complessità del task legata alla mutua sovrapposizione tra rettili e anfibi.

7 Conclusione

Il progetto ha permesso di sviluppare un sistema solido per la classificazione tassonomica degli animali. La rimozione dell'outlier "girl" e il mantenimento delle due rane distinte (**frog_common** e **frog_venomous**) hanno purificato la qualità informativa del dataset. La Support Vector Machine con kernel RBF si è dimostrata il classificatore ottimale, offrendo un'eccellente capacità di generalizzazione e confermando l'importanza di adeguate scelte di preprocessing in contesti caratterizzati da piccoli volumi di dati e sbilanciamento di classe.